

Modelado y control por Aprendizaje por Refuerzo de un convertidor DC-DC Buck

Manuel Santiago Velásquez López
Departamento de Ingeniería Electrónica
Universidad de Antioquia
msantiago.velasquez@udea.edu.co

Resumen—Este informe documenta el desarrollo de un marco avanzado de identificación de sistemas y control adaptativo para un convertidor electrónico de potencia tipo Buck que exhibe dinámicas no lineales, incluyendo resonancias LC y conducción discontinua (DCM). Inicialmente se evaluaron arquitecturas secuenciales profundas tradicionales (LSTM, GRU, NARX-MLP), las cuales fallaron debido a la atenuación de frecuencias al submuestrear y no convergencia al sobremuestrear. Para mitigar esto, se diseñó e implementó una Red de Eco de Estado (ESN) multiescala que opera a alta velocidad (20 kHz), aislando los modos resonantes rápidos de las estimaciones lentas de resistencia de carga. El control regulador final se abordó mediante Aprendizaje por Refuerzo (RL) utilizando el algoritmo *SoftActor-Critic* (SAC). Los resultados muestran que, a pesar de que el modelo ESN superó moderadamente las pruebas de diagnóstico estáticas en lazo abierto, el acoplamiento en lazo cerrado con el agente de RL reveló inestabilidades al rededor del punto de operación.

I. INTRODUCCIÓN Y RELEVANCIA DEL PROBLEMA

La regulación precisa de voltaje en convertidores de potencia DC-DC (tipo Buck) representa un desafío clásico en la electrónica de potencia, con aplicaciones que abarcan desde la gestión de energía en microprocesadores hasta sistemas de propulsión aeroespacial y microrredes de energía renovable. El convertidor Buck estudiado es un sistema físico real caracterizado por dinámicas transitorias rápidas, dependencias paramétricas no lineales (como la variación de la resistencia de carga R) y la existencia de una frecuencia de resonancia intrínseca inducida por el filtro pasivo LC.

El paradigma de control convencional depende críticamente de la linealización en pequeña señal en torno a un punto de operación específico. Sin embargo, ante variaciones severas en el voltaje de entrada V_{in} o en la carga R , este enfoque lineal degrada su desempeño. Este proyecto aborda el problema dividiéndolo en dos tareas secuenciales de Inteligencia Artificial:

1. *Tarea de Regresión (Identificación del sistema)*: Modelado de la dinámica temporal del convertidor para predecir el siguiente estado de voltaje V_{k+1} en función del historial de voltajes, ciclos de trabajo d_k y estimaciones del modo de operación.
2. *Tarea de Aprendizaje por Refuerzo (Control Inteligente)*: Un agente autónomo interactúa de forma adaptativa con el entorno emulado para descubrir una política óptima de modulación que mantenga el voltaje de salida estable en 12,0 V frente a perturbaciones extremas.

II. TRABAJO RELACIONADO

La literatura científica en control inteligente de convertidores de potencia identifica limitaciones fundamentales en los métodos puramente lineales y en los enfoques de aprendizaje profundo de caja negra. Jaeger y Haas [1] introducen el concepto de *Reservoir Computing* mediante Redes de Eco de Estado (ESN), demostrando que la fijación aleatoria de pesos en una capa oculta recurrente masiva elimina la necesidad de retropropagación a través del tiempo y permite capturar dinámicas oscilatorias no lineales con un costo computacional mínimo mediante regresión Ridge en la capa de salida. Por su parte, Haarnoja et al. [2] desarrollan el algoritmo *Soft Actor-Critic* (SAC), un enfoque de optimización de políticas basado en máxima entropía para espacios de acción continuos que se destaca por su eficiencia de muestreo y robustez en sistemas robóticos físicos, superando a metodologías de gradiente de política deterministas propensas a mínimos locales. En contraste, estudios previos que implementan celdas LSTM y GRU evidencian problemas de parálisis de análisis y desvanecimiento de gradiente cuando se intenta modelar dinámicas físicas con altas tasas de muestreo en tiempo real, agravados por latencias de inferencia incompatibles con bucles de control de micro-segundos.

III. DATOS E INGESTION DE PIPELINE

Los datos provienen de capturas experimentales de un convertidor físico Buck real instrumentado. El volumen de datos total asciende a decenas de archivos estructurados en formato de arreglos binarios comprimidos (.npz).

III-A. Tipos de Capturas Experimentales

- *Sequence (Secuencias)*: Capturas con excitación de banda ancha para identificación general del sistema (100 niveles de ciclo de trabajo dinámicos, 466 880 muestras por archivo).
- *Hold (Mantenimiento)*: Capturas a ciclo de trabajo constante destinadas a la caracterización del estado estacionario y mapeo de curvas de ganancia de CD.
- *Chirp (Barridos de Frecuencia)*: Inyecciones sinusoidales con variación lineal de frecuencia (320 000 muestras, 4 segundos de duración) esenciales para el análisis de respuesta en frecuencia (Bode).

III-B. Preprocesamiento y Calibración Monolítica

Las lecturas directas del pin del convertidor se reciben como enteros crudos del ADC (0 a 4095). Se identificó que la tabla de calibración original presentaba dos filas anómalas no monotonicas debido a errores tipográficos de registro en el hardware: las coordenadas (2517 mV, 24,1 V) y (2157 mV, 29,0 V).

Para corregir esto de forma rigurosa, el pipeline unificado (`data_preparation.py`) remueve dichas filas y aplica un interpolador polinomial cubico de Hermite que preserve la forma (`PchipInterpolator`). Esto garantiza matemáticamente la monotonicidad de la conversión analogico-digital, vital para que los gradientes del controlador no inviertan el signo de la acción.

Cuadro I
ESTRUCTURA DEL DATASET CONSOLIDADO TRAS EL PIPELINE DE VERIFICACIÓN

Modo	Archivos	Muestras/archivo	Proposito
Sequence	14	466 880	Entrenamiento ESN/LSTM
Chirp	5	320 000	Análisis de Bode
Hold	12	Variables	Curvas de ganancia CD

IV. METODOLOGÍA DE MODELADO Y CONTROL

IV-A. Analisis Automatico de Autocorrelacion Temporal

Antes de entrenar los modelos, se implemento una etapa analítica automática que evalúa la función de autocorrelacion del voltaje:

$$R_{vv}(\tau) = \frac{1}{(N - \tau)\sigma^2} \sum_{k=1}^{N-\tau} (v_k - \mu)(v_{k+\tau} - \mu) \quad (1)$$

El script calcula el desfase exacto en el que la correlación decae por debajo de un umbral de significancia del 10% ($R_{vv} < 0,1$). Este parámetro define la longitud de secuencia optima (seq_len), evitando la configuración empírica arbitraria que suele ralentizar la convergencia de modelos neuronales. El resultado de este análisis se muestra en la figura 1.




Figura 1. Función de autocorrelacion del voltaje de salida. La linea discontinua indica el umbral del 10% que define seq_len .

IV-B. Modelos Secuenciales de Aprendizaje Profundo

Inicialmente se estructuraron arquitecturas basadas en capas recurrentes LSTM, GRU y redes autorregresivas lineales exogenas mediante perceptrones multicapa (NARX-MLP). Estos modelos se entrenaron sobre un vector de estado de tres canales:

$$U_k = [\text{mean_}v_k, \text{duty}_k, \text{op_est}_k] \quad (2)$$

donde $\text{op_est}_k = \text{mean_}v / (\text{duty} + \epsilon)$ actúa como proxy indirecto para estimar el voltaje de entrada instantáneo V_{in} . Las curvas de entrenamiento de cada arquitectura se presentan en las figuras 2–4.




Figura 2. Curva de entrenamiento del modelo GRU baseline.




Figura 3. Curva de entrenamiento del modelo LSTM baseline.




Figura 4. Curva de entrenamiento del modelo NARX-MLP.

Estos modelos obtuvieron perdidas de entrenamiento bajas en conjuntos intra-envolvente. No obstante, su desempeño en el lazo cerrado de RL fue deficiente, como se documenta en la sección de resultados.

IV-C. Red de Eco de Estado Multiescala (v4)

Para abordar el problema de la resonancia no representada, se implemento una arquitectura Echo State Network multiescala (v4) operativa a alta velocidad ($HS_RATE=4$, equivalente a 20 kHz de tasa de muestreo interna). A esta frecuencia, el ciclo de resonancia LC posee un periodo de aproximadamente 9.5 pasos de simulación, lo que lo hace representable para el modelo.

El reservorio de neuronas ($N_{res} = 500$) se segmentó en dos subgrupos acoplados con dinámicas diferenciadas:

1. **Grupo Rápido (FAST):** 350 neuronas con tasa de fuga $\alpha_{fast} = 0,40$ y radio espectral de 0,97, configurado para rastrear dinámicas transitorias de alta frecuencia (ancho de banda efectivo de aproximadamente 2546 Hz).
2. **Grupo Lento (SLOW):** 150 neuronas con tasa de fuga $\alpha_{slow} = 0,10$ y radio espectral de 0,997, configurado con una memoria temporal extendida de aproximadamente 167 ms para estimar implícitamente la resistencia de carga R .

La ecuación de actualización del estado acoplado del reservorio es:

$$\tilde{x}_k = \tanh(U_k W_{in} + x_{k-1} W_{res}) \quad (3)$$

$$x_k = (1 - \alpha) \odot x_{k-1} + \alpha \odot \tilde{x}_k \quad (4)$$

donde α es un vector de coeficientes de fuga expandidos por bloque y $\odot$ representa el producto de Hadamard. Los pesos de salida W_{out} se calculan mediante regularización de Ridge (Tikhonov):

$$W_{out} = (X^T X + \lambda I)^{-1} X^T Y \quad (5)$$

IV-D. Diseño del Bucle de Control por Aprendizaje por Refuerzo

El entorno de control Gym se implementó en `rl_pipeline.py`, incorporando las siguientes condiciones de operación: ruido gaussiano en la lectura del ADC ($\sigma = 0,02$ V), coeficiente de rizo de voltaje de 0,17 y un retraso de acción de hardware de `ACTION_DELAY = 1` paso. La función de recompensa penaliza la desviación absoluta respecto al setpoint de referencia con un término adicional de suavizado de acción:

$$r_k = -|V_k - 12,0| - \gamma(\Delta d_k)^2 \quad (6)$$

V. RESULTADOS

V-A. Analisis de Respuesta en Frecuencia

El script `bode_analysis.py` calculó la función de respuesta en frecuencia (FRF) del convertidor a partir de las capturas de tipo chirp. Los resultados de ganancia y calidad de la estimación se presentan en las figuras 5 y 6.




Figura 5. Ganancia de la FRF del convertidor Buck en función de la frecuencia.




Figura 6. Indicador de calidad de la estimación espectral por segmento de frecuencia.

La figura de ganancia muestra errores de hasta +65 dB en los extremos de la banda cuando se utiliza una ventana de Hann, atribuibles a la atenuación que dicha ventana introduce en los extremos temporales de una señal chirp lineal. Al sustituir la ventana de Hann por una ventana rectangular, los errores en los bordes de banda desaparecieron. Los datos de fase generados no son utilizables: aunque se aplicó `np.unwrap` para corregir las discontinuidades de fase, la función se aplicó sobre el espectro completo desde DC, donde la señal de excitación es dominada por ruido. Esto acumuló rotaciones arbitrarias que se propagaron como un offset de gran magnitud hacia la banda válida de 100–8000 Hz, produciendo valores de fase del orden de $-400\,000$ grados en algunas frecuencias. Los datos de ganancia son físicamente razonables y se utilizaron en etapas posteriores; los datos de fase requieren ser recalculados aplicando `np.unwrap` únicamente dentro de la banda válida.

V-B. Desempeño de los Modelos en Lazo Abierto

Los resultados de entrenamiento y validación de los modelos se muestran a continuación. La figura 7 presenta las capturas crudas utilizadas para entrenamiento, y la figura 8 las utilizadas para validación.




Figura 7. Ejemplos de capturas crudas del convertidor utilizadas en el conjunto de entrenamiento.




Figura 8. Ejemplos de capturas utilizadas en el conjunto de validación.

La figura 9 presenta una comparación directa del rollout en lazo abierto entre las arquitecturas evaluadas, y la figura 10 muestra el desempeño sobre el conjunto de validación.




Figura 9. Comparación del error de rollout en lazo abierto entre los modelos evaluados.




Figura 10. Comparación del desempeño de los modelos sobre el conjunto de validación.

La figura 11 muestra el rollout del modelo ESN v4 y la figura 12 su respuesta en frecuencia estimada.




Figura 11. Rollout del modelo ESN v4 sobre secuencias de validación.




Figura 12. Respuesta en frecuencia estimada del modelo ESN v4.

Las métricas comparativas entre arquitecturas se resumen en la tabla II.

Cuadro II
METRICAS DE ERROR DE LOS MODELOS EVALUADOS EN LAZO ABIERTO

Arquitectura	RMSE Rollout (mV)	Monotonicidad CD	Estabilidad
GRU Baseline (2 kHz)	1240.2	Parcial	No
LSTM Baseline (2 kHz)	985.4	Parcial	No
ESN v3 Single-Res (20 kHz)	640.1	No (21–27V)	No
ESN v4 Multi-TS	284.7	Si	Parcial

Las figuras 13 y 14 presentan los resultados de validación cruzada leave-one-out y walk-forward respectivamente.




Figura 13. Resultados de validación cruzada leave-one-out.




Figura 14. Resultados de validación cruzada walk-forward.

V-C. Desempeño del Agente de RL en Lazo Cerrado

Se realizaron cuatro ejecuciones de entrenamiento de RL con distintas configuraciones. La primera, basada en los modelos GRU/LSTM entrenados a 2 kHz, no suprimió la oscilación debido a que el modelo de planta no representaba la resonancia LC, como se describió en la sección de metodología.

Las ejecuciones posteriores utilizaron el modelo ESN v4. La segunda ejecución produjo un error en estado estacionario de 6921 mV. Se identificó que `rl_buck.py` no llamaba a `plant.reset()` en `BuckEnv.reset()`, por lo que el

estado del reservorio ESN se transfería entre episodios. Esto produjo dinámicas inconsistentes entre episodios y evitó la convergencia de la función de valor del agente SAC.

La tercera ejecución, con este problema corregido, redujo el error a 2311 mV, confirmando que la ausencia de `plant.reset()` había contribuido a los resultados de la segunda ejecución. No obstante, el error seguía siendo superior al objetivo de 100 mV. La causa probable identificada fue la inestabilidad de arranque en frío del reservorio: al llamar a `plant.reset()` sin condiciones iniciales, el reservorio se zerificaba y requería varios cientos de milisegundos para estabilizarse, un tiempo comparable o superior a la duración de cada episodio de 200 ms.




Figura 15. Respuesta al escalon del sistema en lazo cerrado con el agente SAC y el modelo ESN v4 (cuarta ejecución).

La cuarta ejecución incorporó un calentamiento del reservorio mediante 2000 pasos internos a las condiciones iniciales del episodio, redujo el conjunto de condiciones de entrenamiento de 18 a 8 eliminando las condiciones con RMSE superior a 500 mV, elevó el ciclo de trabajo mínimo de 0.05 a 0.25, y redujo el cambio máximo de ciclo de trabajo por paso de 0.05 a 0.02. Esta ejecución tampoco alcanzó las metas de regulación; el modo de falla específico no fue registrado antes de que se agotara el tiempo disponible.

La figura 15 muestra la respuesta al escalón del sistema en lazo cerrado con el agente SAC de la cuarta ejecución.

La figura 16 muestra el desempeño del agente evaluado en distintos regímenes de operación.




Figura 16. Desempeño del agente de RL evaluado en distintos regímenes de operación del convertidor.

VI. DISCUSIÓN

VI-A. Efecto del Preprocesamiento en los Modelos Secuenciales

Los modelos GRU, LSTM y NARX-MLP obtuvieron errores de entrenamiento reducidos en conjuntos intra-envolvente pero no generalizaron correctamente al lazo cerrado. El preprocesamiento heredado promediaba 40 muestras del ADC por paso de control, reduciendo la tasa efectiva a 2 kHz y eliminando el contenido espectral por encima de 1 kHz. Dado que la frecuencia de resonancia LC del convertidor se ubica aproximadamente a 2 kHz, esta pudo haber sido suprimida del conjunto de datos de entrenamiento. La relación entre la tasa de muestreo y la representación de dinámicas rápidas en modelos recurrentes ha sido documentada en trabajos previos [4], donde se muestra que tasas de muestreo insuficientes dificultan el aprendizaje de dependencias temporales de alta frecuencia en redes recurrentes.

VI-B. Comportamiento del Modelo ESN v4 en Lazo Abierto

El modelo ESN v4 obtuvo un RMSE de rollout de 284.7 mV, inferior al de las arquitecturas anteriores, y superó las pruebas de determinismo, monotonicidad de ganancia estática y estabilidad ante ciclo de trabajo constante del script `preflight_checks.py`. Estos resultados son consistentes con las propiedades documentadas de las ESN para capturar dinámicas oscilatorias de banda ancha [1].

VI-C. Limitaciones en Lazo Cerrado

Al integrar el modelo ESN v4 en el pipeline de entrenamiento de RL, la recompensa del agente no convergió y el sistema no alcanzó las metas de regulación generalizada. Una posible causa es la discrepancia entre la distribución de entradas durante el entrenamiento en lazo abierto y las entradas generadas por el agente durante la exploración en lazo cerrado. Este fenómeno, conocido en la literatura como distribución shift o covariate shift, ha sido identificado como una fuente común de degradación en modelos de transición aprendidos utilizados para control [5]. En particular, Lambert et al. [5] documentan que modelos con bajo error de predicción en lazo abierto pueden producir estimaciones divergentes cuando se utilizan en lazo cerrado con un agente que genera acciones fuera del soporte de los datos de entrenamiento.

Una segunda posible limitación es la presencia de operación en Modo de Conducción Discontinua (DCM) en regiones de voltaje de entrada bajo y resistencia de carga elevada. En DCM, el comportamiento del convertidor queda determinado por relaciones algebraicas estáticas distintas a las ecuaciones diferenciales que gobiernan el Modo de Conducción Continua (MCC), lo que representa un cambio estructural en la dinámica del sistema [3]. Un modelo entrenado exclusivamente sobre datos en MCC podría no capturar este cambio, aunque confirmar que el sistema operó en DCM durante los episodios de falla y que esto contribuyó a la inestabilidad observada requeriría experimentos adicionales orientados a aislar esta condición.

Cabe señalar que ambas hipótesis son consistentes con el comportamiento observado pero no han sido verificadas mediante experimentos controlados que aíslen cada factor de forma independiente. Otros factores no considerados, como el tamaño del reservorio, la configuración de hiperparámetros o el diseño de la función de recompensa, podrían haber contribuido igualmente a los resultados obtenidos.

VII. CONSIDERACIONES ETICAS

Los datos utilizados en este trabajo fueron recolectados directamente de una planta física real instrumentada en el laboratorio y no están sujetos a derechos de autor, dado que describen únicamente propiedades físicas macroscópicas de un circuito eléctrico. Por lo tanto, no existen implicaciones de privacidad que deban considerarse en el manejo o la publicación de estos datos. Las aplicaciones típicas de sistemas de control de convertidores de potencia incluyen la gestión de energía en dispositivos electrónicos, vehículos eléctricos y sistemas de distribución. En estos contextos, una falla en

el lazo de control puede producir sobrevoltajes que dañen el hardware conectado o generen condiciones de operación fuera de los límites seguros del convertidor. Este trabajo identifica condiciones específicas bajo las cuales el modelo propuesto no garantiza estabilidad, lo que debe considerarse antes de cualquier despliegue en hardware real.

El uso de modelos de aprendizaje automático para control se justifica cuando el modelado analítico por primeros principios resulta impráctico debido a no linealidades paramétricas o variaciones en los componentes. Sin embargo, los resultados de este trabajo ilustran que un modelo con buen desempeño en lazo abierto no garantiza estabilidad en lazo cerrado, en particular cuando las acciones del controlador llevan el sistema fuera del dominio de entrenamiento o cuando el sistema presenta cambios estructurales como la transición a DCM. El uso en aplicaciones críticas requiere la incorporación de mecanismos de supervisión y protección independientes del modelo aprendido.

VIII. ESTRUCTURA Y DIVISION DEL TRABAJO

Las responsabilidades del proyecto se distribuyeron de la siguiente manera:

- *Linea de Datos y Senales:* Desarrollo de `data_preparation.py`, corrección del interpolador Pchip monotonico e identificación del error de ventana en `bode_analysis.py`.
- *Linea de Modelado y Reservorios:* Diseño del reservorio multiescala de la red ESN v4 en `train_plants.py`, implementación de la rutina de autocorrelacion y desarrollo del script de diagnostico estático `preflight_checks.py`.
- *Linea de Aprendizaje por Refuerzo y Entornos:* Desarrollo del entorno Gym en `rl_pipeline.py`, ajuste de la función de recompensa y análisis de la inestabilidad en lazo cerrado.

IX. CONCLUSIONES

Se implementó y evaluó un framework de identificación de sistemas y control adaptativo para un convertidor Buck no lineal utilizando celdas recurrentes tradicionales y redes de reservorio.

Las arquitecturas LSTM, GRU y NARX-MLP entrenadas a 2 kHz no generalizaron correctamente al lazo cerrado, lo que es consistente con la dificultad conocida de los modelos recurrentes para representar dinámicas de alta frecuencia cuando la tasa de muestreo es insuficiente [4].

La arquitectura ESN multiescala v4 operada a 20 kHz redujo el RMSE de rollout en lazo abierto a 284.7 mV y superó con éxito todas las pruebas de diagnóstico estático.

El acoplamiento final con el agente SAC en lazo cerrado no alcanzó las metas de regulación generalizada debido a inestabilidades transitorias y divergencias en los extremos de operación.

Los resultados observados en el lazo cerrado son consistentes con los efectos de distribution shift documentados en modelos aprendidos para control [5], aunque no es posible

atribuir la falla a esta causa de forma concluyente a partir de los experimentos realizados.

La posible presencia de operación en Modo de Conducción Discontinua (DCM) en ciertos regímenes representa una limitación estructural adicional que requiere verificación experimental debido a sus discontinuidades algebraicas [3].

El resultado principal de este trabajo demuestra experimentalmente que un buen desempeño en lazo abierto no es condición suficiente para garantizar la estabilidad en lazo cerrado, una observación reportada previamente en el control basado en modelos aprendidos [5].

Los trabajos futuros deberían abordar estas limitaciones mediante la recolección de datos en lazo cerrado, la inclusión explícita de condiciones de DCM en el entrenamiento o el uso de arquitecturas híbridas que combinen el modelo aprendido con restricciones analíticas del circuito físico.

REFERENCIAS

- [1] H. Jaeger and H. Haas, “Harnessing Nonlinearity: Predicting Chaotic Systems and Saving Energy in Wireless Communication,” *Science*, vol. 304, no. 5667, pp. 78–80, Apr. 2004.
- [2] T. Haarnoja, A. Zhou, P. Abbeel, and S. Levine, “Soft Actor-Critic: Off-Policy Maximum Entropy Deep Reinforcement Learning with a Stochastic Actor,” in *Proc. 35th Int. Conf. Machine Learning (ICML)*, 2018, pp. 1861–1870.
- [3] R. W. Erickson and D. Maksimovic, *Fundamentals of Power Electronics*, 2nd ed. Norwell, MA: Kluwer Academic, 2001.
- [4] C. Tallec, L. Blier, and Y. Ollivier, “Can Recurrent Neural Networks Warp Time?” in *Proc. 6th Int. Conf. Learning Representations (ICLR)*, 2018. [Online]. Available: <https://arxiv.org/abs/1804.11188>
- [5] N. Lambert, A. Willets, O. Calandra, M. W. Mueller, and S. Levine, “The Challenges of Continuous Control with Deep RL,” *arXiv preprint arXiv:2202.11328*, 2022. [Online]. Available: <https://arxiv.org/abs/2202.11328>